

MLOps & Monitoring Plan

4.11.1 مقدمه

اگرچه در حال حاضر مبتنی بر قوانین ساده `nobatnou.ir` سیستم پیش‌بینی زمان انتظار در ارتقاء خواهد یافت. این سند (ML) است، اما به تدریج به مدل‌های یادگیری ماشین (rule-based) و **مانیتورینگ مستمر** را تعریف (در محیط عملیاتی ML اداره مدل‌های) **MLOps** چارچوب می‌کند تا اطمینان حاصل شود که مدل‌ها قابل اعتماد، قابل نگهداری و قادر ریسک‌های عملیاتی هستند.

4.11.2 اهداف MLOps**

- مدل در محیط تولید همواره در دسترس و پایدار باشد **Reliability** (قابلیت اطمینان)
- هر نسخه از مدل و نتایج آن قابل بازتولید باشد **Reproducibility** (قابلیت بازتولید)
- فرآیندهای آموزش و استنتاج با رشد داده‌ها مقیاس پذیرند **Scalability** (مقیاس‌پذیری)
- به طور مستمر پایش شود drift عملکرد مدل، کیفیت داده و **Monitoring** (مانیتورینگ)
- کاهش مداخله دستی در چرخه حیات مدل **Automation** (خودکارسازی)

4.11.3 چرخه حیات مدل (Model Lifecycle)**


#:مراحل چرخه حیات مدل در نوبت نو** # ## #


1. **جمع‌آوری داده (Data Collection)**
 2. **آماده‌سازی داده (Data Preparation)**
 3. **آموزش مدل (Model Training)**
 4. **ارزیابی (Evaluation)**
 5. **تست استقرار (Deployment Testing)**
 6. **استقرار (Deployment)**
 7. **مانیتورینگ و پایش (Monitoring & Observability)**
 8. **بازآموزی (Retraining)**
 9. **نسخه‌بندی و بایگانی (Versioning & Archival)**
-

4.11.4 معماری MLOps (MLOps Architecture)

#: ساختار پیشنهادی (بر اساس مقیاس فعلی) # ## #

...





اجزای کلیدی^{**}:

- **Feature Store:** مثلاً ذخیره ویژگی‌های از پیش محاسبه شده `avg_wait_time_last_week`).
- **Model Registry:** ثبت و نسخه‌بندی مدل‌ها با استفاده از **MLflow**^{**} یا **DVC**^{**}.

- **Training Pipeline:** اسکریپت‌های خودکار آموزش با GitHub Actions.
 - **Serving API:** سرویس مدل با FastAPI درون Docker.
 - **Monitoring Dashboard:** نمایش متریک‌های مدل و داده.
-

4.11.5 مانیتورینگ مدل (Model Monitoring)

(الف) مانیتورینگ عملکرد (Performance Monitoring)**

- **متریک‌های کلیدی تحت پایش**
- | متریک | هدف | آستانه هشدار | ابزار اندازه‌گیری |
 - | ----- | ----- | ----- | ----- |
- | دقت پیش‌بینی | < ۲۰ دقیقه | محاسبه روزانه بر اساس داده‌های واقعی
- | درصد پیش‌بینی‌های درون محدوده* | قابلیت اطمینان | > ۵۰٪ (محدوده ± 20 دقیقه) | محاسبه هر ۶ ساعت
- | API کارایی | ثانیه ۱ > Latency** | زمان پاسخگویی مدل** | APM (New Relic/Sentry)
- | Nginx | نرخ درخواست‌های ناموفق** | در دسترس بودن | < ۵٪ | لاغ‌های*

**هشدارها

- از ۲۰ دقیقه عبور کرد → هشدار سطح ۲ (ایمیل به تیم داده) اگر MAE

از ۳۰ دقیقه عبور کرد → **هشدار سطح ۱** (تماس با مدیر فنی) MAE اگر -

(انحراف) Drift ب) مانیتورینگ**

| نحوه تشخیص | فرکانس | آستانه هشدار | Drift نوع |

| ----- | ----- | ----- | ----- |

| **Data Drift** | بین هفته (`hour_of_day` مانند) مقایسه توزیع ویژگی‌های ورودی | جاری و گذشته | هفتگی $KL\text{ Divergence} > 0.2$ |

| **Concept Drift** | هفته گذشته | هفتگی | افزایش MAE مقایسه | هفتگی $MAE > 10\%$ |

| **Label Drift** | ماهانه | (`actual_wait` تغییر توزیع زمان واقعی انتظار | Kolmogorov-Smirnov test p-value < 0.05 |

:ابزار تشخیص

- Python: `alibi-detect`, `evidently`.

- Dashboard: **Grafana** با داده‌های محاسبه شده.

(ج) مانیتورینگ زیرساخت** (Infrastructure Monitoring)**

- **Netdata** با منابع سرور: CPU، RAM، I/O.

- Docker API endpoint، سلامت سرویس مدل: **وضعیت کانتینر**.

- **دیتابیس ویژگی‌ها:** اتصالات، حجم داده.

4.11.6 (Model Versioning) نسخه‌بندی و مدیریت مدل

سیاست نسخه‌بندی **

مدیریت می‌شوند `MAJOR.MINOR.PATCH` نسخه‌ها به صورت -

- `MAJOR` تغییرات اساسی در معماری مدل یا ویژگی‌ها:

- `MINOR` بهبود دقت یا افزودن ویژگی جدید:

- `PATCH` رفع باگ یا بهینه‌سازی جزئی:

ذخیره‌سازی **

| مؤلفه | محل ذخیره | ابزار |

| ----- | ----- | ----- |

| **کد آموزش** | GitHub (با tagging) | Git |

| **مدل آموزش‌دیده** | مدل + Metadata در MLflow | MLflow Tracking |

| **دیتابست‌ها** | Object Storage (مثلًا MinIO) + DVC | DVC |

| در مخزن کد YAML هایپرپارامترها** | فایل* | Git |

نمونه ساختار فایل‌ها **

...

models/

 | └── v1.0.0/

 | | └── model.pkl

4.11.7 فرآیند بازآموزی (Retraining Pipeline)

محرک‌های بازآموزی (Retraining Triggers):**

۱. هر ۲ هفته یکبار (**Scheduled**) زمان‌بندی شده.

۲. دقیقه برای ۳ روز (**Performance-based**) اگر $MAE > 20$ بروز اساس عملکرد.

۳. از آستانه عبور کند (**Drift-based**) اگر Drift بر اساس

۴. پس از جمع‌آوری ۵۰۰ نمونه جدید (**Data Volume-based**) بر اساس حجم داده.

#:مراحل خودکار بازآموزی**

۱. جمع‌آوری داده جدید از ۲ هفته اخیر.

۲. اجرای آموزش `train.py` با اسکریپت.

۳. ارزیابی مدل جدید روی داده‌های اعتبارسنجی.

4. **مقایسه با مدل فعلی (A/B testing).

5. اگر بهتر بود: **ثبت در Model Registry.

6. **تست استقرار در محیط staging.

7. انتخاب برای استقرار توسط مدیر مدل.

GitHub Actions یا **Airflow** خودکارسازی با.

4.11.8 (Pre-deployment Testing)

#: مراحل تست

| مرحله | هدف | روش |

| ----- | ----- | ----- |

| **Unit Testing** روی کد Python | تست توابع آماده‌سازی داده و آموزش |

| **Integration Testing** (داده → مدل → end-to-end pipeline) | تست

| روی داده‌های ساختگی pipeline پیش‌بینی) | اجرای

(مجازی) | مقایسه مدل جدید با مدل فعلی روی داده‌های تاریخی | محاسبه

| متريک‌ها برای هر دو

| **Canary Deployment** (1%) تست مدل جدید روی بخش کوچکی از ترافیک واقعی |

| routing با load balancer |

| **Stress Testing** | سرویس مدل API تست بار بر روی locust` یا k6` |

معيار های پذيرش (Acceptance Criteria):**

- كمتر** از مدل فعلی داشته باشد (يا حداكثر 5% بدتر) مدل جديد باید -
 - هیچ ویژگی حیاتی** نباید حذف شده باشد** -
 - زمان استنتاج** باید زیر ۵۰۰ میلی ثانیه باشد** -
 - تست های یکپارچگی** همه باید عبور** کنند -

4.11.9 Rollback (Deployment & Rollback)

استراتژی استقرار **

- **Blue-Green Deployment:**

- مدل فعلی: (Blue) **(آبی) v1.0.0.
- مدل جدید: (Green) **(سبز) v1.1.0.
- پس از تست، ترافیک به تدریج به سبز منتقل می شود -

روش Rollback:**

شناسایی مشکل: ** از طریق هشدار ها یا گزارش کاربران** . ۱.

مدیر مدل تأیید می کند **Rollback: تصمیم** . ۲.

۳. ** تغییر مسیر ترافیک: بازگشت به محیط آبی (مدل قبلی) از طریق** load balancer.

۴. ** بررسی علت: تحلیل لگ ها و داده ها برای شناسایی ریشه مشکل** .

کمتر از ۱۵ دقیقه از شناسایی تا بازیابی** Rollback زمان هدف**

4.11.10) مسئولیت‌ها و نقش‌ها (Roles & Responsibilities)

نقش مسئولیت‌ها فرد/تیم
----- ----- -----
تأثید انتشار، نظارت بر عملکرد، تصمیم‌گیری (Model Owner) مدیر مدل**
Rollback مدیر فنی
آموزش مدل، نگهداری زیرساخت pipeline توسعه ML مهندس**
MLOps تیم داده
توسعه API یکپارچه‌سازی مدل با مهندس نرم‌افزار**
سرویس‌های همراه تیم توسعه
گزارش‌دهی عملکرد، پیشنهاد بازآموزی Data Analyst) تحلیلگر داده**
تیم داده
مانیتورینگ زیرساخت، هشدارها، پشتیبان‌گیری تیم فنی پشتیبان عملیاتی** (Ops)

4.11.11) Tool Stack)

دسته ابزار توضیح

کد و کنترل نسخه Git, GitHub **مدیریت کد و نسخه**		
ردیابی آزمایش‌ها، نسخه‌بندی مدل و داده MLflow, DVC **مدیریت مدل**		
خودکارسازی آموزش و پایپ‌لاین GitHub Actions, Apache Airflow		
استقرار		
نمایش متريک‌ها و مانیتورینگ Grafana, Prometheus, Custom Scripts		
هشدار		
و کانتينری‌سازی API FastAPI, Docker, Nginx API سرویس‌دهی مدل		
تست کد، بار و تست pytest, locust, evidently Drift		

4.11.12 برنامه اجرایی (Implementation Roadmap)

(۳ ماه) MLOps فاز ۱: پایه **

- راهاندازی Model Registry با MLflow.

- (روزانه MAE) ایجاد مانیتورینگ ساده.

- آموزش دستی pipeline راهاندازی.

** فاز ۲: خودکارسازی (۶ ماه) **

- GitHub Actions خودکارسازی بازآموزی با.

- Drift. راهاندازی مانیتورینگ.

- Canary Deployment.

فاز ۳: تکمیل (۱۲ ماه) ***

- استقرار کامل Blue-Green Deployment.

- با Real-time Grafana مانیتورینگ.

- Feature Store پکارچه‌سازی.

4.11.13 هزینه‌های MLOps (MLOps Costs)

توضیح	هزینه ماهانه تخمینی	مؤلفه
----- ----- -----	----- ----- -----	----- ----- -----
دلار برای مانیتورینگ پیشرفته (Grafana Cloud) ** ۱۰	دلار برای مانیتورینگ پیشرفته (Grafana Cloud) ** ۱۰	دلار برای مانیتورینگ پیشرفته (Grafana Cloud) ** ۱۰
دلار ذخیره‌سازی Object Storage داده‌ها و مدل‌ها ۵ دلار **	دلار ذخیره‌سازی Object Storage داده‌ها و مدل‌ها ۵ دلار **	دلار ذخیره‌سازی Object Storage داده‌ها و مدل‌ها ۵ دلار **
دلار سرور مجازی (Training/Staging) ** ۲۰	دلار سرور مجازی (Training/Staging) ** ۲۰	دلار سرور مجازی (Training/Staging) ** ۲۰
دلار نیروی انسانی (نیمه‌ وقت ML مهندس) ۵۰۰	دلار نیروی انسانی (نیمه‌ وقت ML مهندس) ۵۰۰	دلار نیروی انسانی (نیمه‌ وقت ML مهندس) ۵۰۰
مجموع ** ۵۳۵ دلار ** برای فاز اول **	مجموع ** ۵۳۵ دلار ** برای فاز اول **	مجموع ** ۵۳۵ دلار ** برای فاز اول **

توجه: ** هزینه‌ها با مقیاس سیستم افزایش می‌یابد**.

نتیجه‌گیری ۴.۱۱.۱۴ **

به گونه‌ای طراحی شده است که مدل‌ها از `nobatnou.ir` و مانیتورینگ MLOps سیستم بمب ساعتی به دارایی پایدار تبدیل کند. با ترکیب خودکارسازی، مانیتورینگ چندلایه و فرآیندهای کنترل شده انتشار، اطمینان حاصل می‌شود که مدل‌ها نه تنها دقیق، بلکه قابل اعتماد، قابل نگهداری و واکنش‌گرا به تغییرات هستند. این سند به عنوان نقشه راه تیم فنی برای حرکت از مدل ساده rule-based ML به سیستم می‌کند.